



T.C.

ÇUKUROVA ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ

ENDÜSTRİ MÜHENDİSLİĞİ
BÖLÜMÜ

Dersin Kodu
BİTİRME ÖDEVİ

KONUSU

Kredi tahsisinde kullanılan karar politikalarının ekonomik sınıflar arasındaki etkisinin makine öğrenmesiyle analiz edilmesi.

HAZIRLAYAN

2022238019 - Mustafa Çeşmeli

DANIŞMAN

Dr. Öğr. Üyesi - Kübra ATEŞ

Ay- Yıl

Ocak

2026

ADANA

İÇİNDEKİLER

ÖZ.....	I
KULLANILAN SİMGELER VE KISALTMALAR.....	III
ŞEKİL LİSTESİ.....	IV
ÇİZELGE LİSTESİ.....	V
1. GİRİŞ.....	1
2. LİTERATÜR ARAŞTIRMASI.....	2
2.1. KREDİ TAHSİSİNDE TEMERRÜT OLASILIĞI.....	2
2.2. KREDİ VERİSİ VE ÖZELLİK ÜRETME	2
2.3. KREDİ SKORLAMA İÇİN TEMEL MODEL AİLELERİ.....	2
2.4. MALİYET DUYARLI KARAR POLİTİKALARI.....	3
2.5. SEGMENT BAZLI DEĞERLENDİRME YAKLAŞIMI.....	4
3. METODOLOJİ.....	5
3.1. VERİ SETİ, DEĞİŞKEN GRUPLARI VE ANAHTARLAR.....	5
3.2. VERİ ÖN İŞLEME VE ÖZELLİK MÜHENDİSLİĞİ.....	8
3.3. MODELLEME VE DOĞRULAMA	9
3.4. PERFORMANS ÖLÇÜMÜ VE KALİTE KONTROLLERİ.....	9
3.5. KARAR EŞİĞİ OPTİMİZASYONU VE POLİTİKA ANALİZİ.....	10
3.6. MODEL YAPI ANALİZİ.....	14
4. BULGULAR.....	15
4.1. MODEL AYRIŞTIRMA BAŞARIMI.....	15
4.2. OLASILIK KALİTESİ ANALİZİ.....	18
4.3. DAĞILIM VE STABİLİTE ANALİZİ.....	19

4.4. MALİYET TEMELLİ OPTİMUM EŞİK VE HATA MATRİSİ.....	20
4.5. DEĞİŞKEN ÖNEM VE MODEL ANALİZİ.....	22
4.6. EKONOMİK SEGMENTLER ARASI KARŞILAŞTIRMA.....	24
4.7. SENARYO ANALİZİ.....	27
5. TARTIŞMA.....	29
6. SONUÇ.....	32
KAYNAKLAR.....	34
TURNİTİN RAPORU.....	38
TEŞEKKÜR.....	41
ÖZGEÇMİŞ.....	42

ÖZ

Bu çalışmada kredi tahsisi sürecinde önemli bir yeri olan temerrüt riskinin tahmin edilmesi, bu tahminlerin minimum maliyet yaklaşımına göre eşiklendirilmiş bir karar kuralına dönüştürülmesi ve sosyoekonomik gruplar arasındaki etkisinin analiz edilmesi süreci simüle edilmiştir.

Çalışmanın temel amacı risk tahminleme yöntemlerinin yalnızca skor tahminlemeye odaklı değil maliyet temelli bir karar kuralı üzerinden işlenmesini sağlamak ve bu kuralın ekonomik sınıflar arasında adil bir etki yapıp yapmadığını analiz etmek ve bu etkinin olası kaynaklarını değerlendirmektir.

Çalışmada Home Credit Default Risk yarışmasının veri seti kullanılmıştır. Veri seti çoklu tablolulu bir yapıdadır. Başvuran kişinin başvuru anı verileri ile geçmiş ödeme davranışını içermektedir. Tahminleme için LightGBM modeli kullanılmıştır

Train test verisi ayrımında k fold yöntemi kullanılmış ve 10 fold üzerinden incelenmiştir. Modelin skor başarı değerleri için 10 foldun ortalaması hesaplanmıştır. Modelin olasılık kalitesinin ölçülmesi için kalibrosyon eğrisi ve Brier skoru hesaplanmıştır. Modelin train- test verisi arasındaki başarısının analiz edilmesi için PSI hesaplanmıştır. Tahminlenen temerrüt olasılığının karar kuralı haline getirilebilmesi için cut off eşiği hesaplanmıştır. Bu eşik çerçevesinde modelin hata matrisi raporlanmıştır. Modelin açıklanabilirliği için Shap analizi kullanılmıştır.

İkinci aşamada maliyet temelli eşiğe göre belirlenmiş karar kuralının sosyoekonomik gruplar arasındaki etkisinin analiz edilmesi için örneklem kişi başı gelir seviyesi üzerinden 3 gruba ayrılmış ve bu gruplar üzerindeki reddedilme oranları ve hata oranları analiz edilmiştir.

Bu analizin sonuçları tek eşikli karar kuralının ekonomik gruplar için düzenli bir trend yapısı oluşturduğunu göstermiştir. Bu analize göre düşük ekonomik sınıf tüm kalemlerde bu karar kuralından daha kötü etkilenirken, yüksek ekonomik sınıf daha iyi etkilenmiştir.

Bu analizin sonucu olarak gelir seviyesinin temerrüt riski üzerinde düzenli bir etkisinin olduğunu göstermiştir. Bu etkinin sebebinin literatürde sıklıkla bahsedilen “Gelir seviyesi temerrüt riski üzerinde doğrudan etkiye sahip değildir, talep edilen kredi tutarı ve onunla ilişkili

diğer veriler üzerinden etki etmektedir” iddiasından kaynaklı olup olmadığının test edilmesi için talep edilen kredi tutarı ve bağlantılı veriler üzerinden yeni bir analiz yapılmıştır. Bu analizde diğer tüm veriler sabit tutulurken bahsedilen bu veriler için (-20%, 1, +20%) düzenlemesi yapılmış ve 3 senaryo oluşturulmuştur. Bu senaryolar için önceden eğitilmiş olan aynı modelle tahminleme yapılmıştır.

Yapılan bu analizin sonucunda talep edilen kredi tutarı ve bağlantılı veriler üzerinden yapılan değişikliğin sonuçlar üzerinde sınırlı değişiklikler yapsa da beklenenin aksine gelir seviyesinden kaynaklanan trend yapısı üzerinde anlamlı bir değişiklik üretememiştir.

Sonuç olarak bu çalışma tek eşikli karar kuralının ekonomik sınıflar arasında adil olmayan bir trend yapısı sergilediğini göstermiştir. Bu yapının sebebinin literatürdeki iddianın aksine talep edilen kredi ve onunla bağlantılı verilerden kaynaklı bir yapı olmadığı görülmüştür.

KULLANILAN SİMGELER VE KISALTMALAR

Kısaltmalar

AUC : ROC eğrisi altında kalan alan

ROC : Alıcı İşletim Karakteristiği eğrisi

KS : Skor ayırıştırma gücü

PSI : Skor dağılımı stabilitesi ölçütü

PD : temerrüt olasılığı

OOF : çapraz doğrulama kapsamında tahminler

CV : çapraz doğrulama

GBDT : gradyan artırmalı karar ağaçları

LightGBM : Light Gradient Boosting Machine; GBDT tabanlı öğrenme algoritması

SHAP : model açıklanabilirlik yöntemi

TreeSHAP : Ağaç tabanlı modeller için SHAP'in hızlı hesaplama yaklaşımı

TP : Doğru pozitif sınıflama

TN : Doğru negatif sınıflama

FP : Yanlış pozitif sınıflama

FN : Yanlış negatif sınıflama

TPR : Doğru pozitif oranı

FPR : Yanlış pozitif oranı

INCOME_PER_PERSON : Kişi başı gelir

INCOME_CREDIT_PERC : Gelir / kredi oranı

PAYMENT_RATE : Taksit / kredi oranı

Semboller

τ : Karar eşiği

% : Yüzde

n : Gözlem sayısı

Σ : Toplam operatörü

μ : Ortalama

σ^2 : Varyans

ŞEKİL LİSTESİ

Şekil 1. Test örnekleminde kişi başı gelir dağılımı	12
Şekil 2. Train ve Test kişi başı gelir yoğunluk histogramı	12
Şekil 3. ROC analizi	15
Şekil 4. KS analizi.....	16
Şekil 5. Kalibrasyon eğrisi ve Brier skoru.....	18
Şekil 6. PSI analizi	19
Şekil 7. Maliyet eşik analizi	20
Şekil 8. Confusion matrisi	21
Şekil 9. SHAP özet görselleştirmeleri	22
Şekil 10. Bağımlılık grafikleri.....	23
Şekil 11. Sosyoekonomik segmentlere göre PD skor dağılımları	24
Şekil 12. Sosyoekonomik segmentlere göre reddetme oranı karşılaştırması	25
Şekil 13. Sosyoekonomik segmentlere göre beklenen hata tipi oranları karşılaştırması.....	26

ÇİZELGE LİSTESİ

Çizelge 1. Veri değişkenleri	5
Çizelge 2. Fold sonuçları	17
Çizelge 3. Sosyoekonomik segmentlere göre politika çıktıları özet metrikleri	26
Çizelge 4. HIGH segmenti için kredi tutarı senaryo analizi çıktıları	27
Çizelge 5. MID segmenti için kredi tutarı senaryo analizi çıktıları	27

Çizelge 6. LOW segmenti için kredi tutarı senaryo analizi çıktıları	28
Çizelge 7. Senaryo analizi özet değişimler	30

1. GİRİŞ

Kredi tahsisinde temel zorluk başvuru anı bilgileriyle temerrüt riskini tahmin edebilmek ve bu süreç için maliyet temelli bir karar kuralı uygulayabilmektir. Bu problemde kredi tahsis edenler başvurunun geliş anındaki verileri ve başvuranın geçmiş ödeme alışkanlıklarını gösteren verileri kullanarak skor tahminlemesi yapmaktadır. Bu olasılık ve talep edilen kredi tutarı üzerinden minimum kayıp maliyeti ve minimum fırsat maliyeti hedefleri arasında optimum bir karar eşiği uygulayarak karar vermeye çalışmaktadır.

Bu çalışmanın temel amacı bu karar sürecinin ekonomik sınıflar arasındaki etkisinin analiz edilmesi ve olası etkilerin kaynağının araştırılması ve incelenmesidir. Bu amaca yönelik çalışmada kredi tahsisinde kullanılan gerçek bir veri seti olan Home Credit Default Risk veri kümesi kullanılmıştır.

Çalışmanın araştırma odağı üç noktaya odaklanmaktadır. Modelin temerrüt riskini analiz etme ve olasılık üretme kapasitesi ne kadar başarılıdır? Maliyet oranlarına göre belirlenen tek eşikli karar kuralı minimum maliyet için hangi eşik değerini belirlemiştir? Bu karar kuralı ekonomik gruplar arasında farklı sonuçlar üretmiş midir, üretmişse bu etkinin kaynağı ne olmuştur?

Üçüncü soru çalışmanın nihai hedeflerindendir. Sosyoekonomik gruplar arasındaki farklılığın doğrudan gelir seviyesi etkisi olarak değil talep edilen kredi tutarı ve onunla bağlantılı diğer veriler üzerinden etki ettiği literatürde bahsedilmektedir [4,5,38]. Çalışmada ekonomik sınıflar arasındaki olası etkinin daha derinlemesine analiz edilmesi ve literatürdeki bu yapının test edilmesi için bahsedilen bu veriler üzerinde kontrollü değişiklikler yapılarak ekonomik sınıflar arasındaki etki yeniden analiz edilmiştir.

2. LİTERATÜR ARAŞTIRMASI

2.1. KREDİ TAHSİSİNDE TEMERRÜT OLASILIĞI

Kredi tahsisinde temerrüt olasılığının tahmini minimum maliyet hedefi için büyük önem oluşturmaktadır. Bankalar tahsis ettikleri kredinin temerrüdü için güvence tutmaktadır. Bu durum temerrüt durumunda hem kayıp maliyetini hem de sermaye maliyetini doğurmaktadır. Bu yüzden maliyet temelli bir eşik belirlenmesi yaygın bir yöntemdir. Bu durumda yaşanan iyyinin reddedilmesi fırsat maliyeti oluşturmaktadır. Sonuç olarak olasılık tahminleri, talep edilen kredi tutarı ve diğer ilişkili maliyet verileri üzerinden hesaplanan minimum kayıp maliyeti ve minimum fırsat maliyetleri arasında optimum bir eşik belirlenmesini gerekli olmaktadır [4,5,35-39].

2.2.KREDİ VERİSİ VE ÖZELLİK ÜRETME

Temerrüt tahmini sürecinde yalnızca başvuru anı verileriyle tahminleme yapmak düşük güvenilirliktedir. Başvuranın geçmiş ödeme alışkanlıkları ve diğer ekonomik bilgilerini içeren çoklu tablolı veri kümesi yapısı daha güvenilir sonuçlar üretilmesini sağlamaktadır [2,3,4,5]. Bu veri kümesi yapısı üzerinden başvuran kimliği baz alınarak toplu bir öz nitelik tablosu üretilmesi yaygın bir kullanımdır. Ayrıca minimum, maksimum, ortalama, toplam ve varyans gibi istatistiklerin oynaklığı yakalayan özetleyici göstergeler olarak kullanılmasının pratikte güçlü sonuçlar verdiği literatürde bahsedilmektedir [2,3,4,5].

2.3.KREDİ SKORLAMA İÇİN TEMEL MODEL AİLELERİ

Kredi skorldama verisinde yer alan kategorik değişkenlerin ve lineer olmayan etkilerin yer alması tahminleme modeli için GBDT ailesini güçlü kılmaktadır. One hot kodlama yöntemiyle kategorik değişkenlerin lineer olmayan etkilerinin modelleme için uygun hale getirmekte ve

toplu tablo yapısının sayısal olarak işlenmesini sağlamaktadır. Bu dönüşüm çok sayıda türetilmiş öznitelik üretildiğinde boyutsallığı arttırmakta ve aşırı uyum riskini ve genelleme performansını güvenilirliğini zorunlu kılmaktadır. Temerrüt olasılığının örneklem içerisinde daha nadir rastlanan bir durum olması ayırıştırma metriklerinin seçimini ve doğrulama tasarımını etkilemektedir [20, 21, 22, 23, 24]. GBDT ailesinde bulunan her iterasyonda zayıf öğrencilerin kayıp fonksiyonu uzayında iyileştirilmesi yapısı modellerin başarısının temel kaynağı olmaktadır.

LightGBM'in histogram tabanlı bölme ve yapraklı odaklı büyüme yapısı büyük veri setlerinde ve geniş özellik uzaylarında bile eğitim kolaylığı, hesaplama verimliliği ve yüksek ayırıştırma başarımı sunduğu için LightGbm sıklıkla tercih edilmektedir [7, 8, 9, 10, 11, 12].

2.4.MALİYET DUYARLI KARAR POLİTİKALARI

Doğrulama ve genelleme ölçümünde performansın daha gerçekçi değerlendirilmesi ve olası aşırı uyum riskine karşı k fold yöntemi kullanılması random split yöntemine göre daha güvenilir bir yöntemdir. K fold yönteminde uygulanan tüm foldlar üzerinden kat dışı tahminlerin (OOF) bu yöntemin ürünüdür. Verinin heterojenliği ve modelin kararlılığını temsil eden bir sinyal olarak tüm kat verilerinin de ayrıca raporlanması gerekmektedir [6, 7].

Ayırıştırma performansının incelenmesi için ROC eğrisi altında kalan alandan oluşan AUC değeri ve KS istatistiği değerlerinin kullanılması literatürde yaygın bir yöntemdir [21, 22]. AUC eşik seçiminden bağımsız sıralama kalitesini temsil etmektedir. KS değeri ise TPR ve FPR arasındaki farkı temsil etmekte ve eşikleme öncesi bir temel göstermektedir.

Kalibrasyon temerrüt tahminin olasılık anlamı taşıyabilmesi için temel bir gerekliliktir. Kredi tahsisinde maliyet ve sermaye olasılıkları beklenen değere dayanmaktadır [35, 39]. Brier skoru olasılık tahmininin doğruluk kalibrasyonunu ölçmek için kullanılan yaygın bir yöntemdir.

Model sonuçlarının zaman ve popülasyon değişimi altında nasıl değiştiğini analiz etmek amacıyla PSI analizi kullanılmaktadır. [35, 39]. PSI tek başına performans bozulması işareti olmamaktadır. Performans metrikleriyle birlikte yorumlandığında model riskinin erken göstergesi olarak işlev gördüğü literatürde bahsedilmektedir [34, 35].

Temerrüt skorlaması kredi tahsis sürecinde karar kuralı için yeterli gelmemektedir. Kayıp ve sermaye maliyetlerine karşıt fırsat maliyeti arasında optimum denge ve minimum maliyet sağlayan bir eşik tasarımı gerekmektedir. Bunun için kayıp maliyeti ve fırsat maliyetinin önceden tanımlanarak modelin karar eşiği belirlemesi sağlanmalıdır. Belirlenen eşik değerine göre uygulanan karar kuralının reddetme oranı ve hata oranları ayrıca izlenmelidir.

2.5. SEGMENT BAZLI DEĞERLENDİRME YAKLAŞIMI

Maliyete göre eşiklendirilmiş karar kuralının ekonomik sınıflar arasında benzer bir etki mi ürettiği yoksa farklı sonuçlar mı ürettiği ayrıca izlenmelidir. Modelin bu ekonomik sınıflar için reddedilme oranlarında, iyinin reddedilmesi ve kötünün kabulü hatalarında nasıl sonuçlar ürettiği analiz edilmelidir.

Ekonomik sınıflar arasında oluşacak olası farklı etkinin kaynağının analiz edilmesi ayrıca gerekmektedir. Sosyoekonomik gruplar arasındaki farklılığın doğrudan gelir seviyesi etkisi olarak değil talep edilen kredi tutarı ve onunla bağlantılı diğer veriler üzerinden etki ettiği literatürde bahsedilmektedir [4,5,38].

3. METODOLOJİ

Bu çalışmada çoklu tablolı kredi başvuru verisini tek başvuru düzeyinde birleştirilmiştir. Başvuru ve davranışsal sinyaller özellik üretimi ile modellenmiştir. Karar eşiği optimizasyonu yapılmış ve bu eşiğin ekonomik segmentler üzerinde etkisi politika senaryosu adı altında analiz edilmiştir. Olasılık çıktısının kalibrasyonu ve skor stabilitesi gibi üretim ortamı gereklilikleri de aynı akış içinde raporlanmıştır.

3.1. VERİ SETİ, DEĞİŞKEN GRUPLARI VE ANAHTARLAR

Çalışmada kullanılan veri seti bireysel kredi başvurularına yönelik düzenlenen Home Credit Default Risk yarışma verisidir. Bu veri kümesinde sadece başvuru anı verileri değil başvuranın geçmiş ödeme davranışları vb. verileri içeren çoklu tablolı bir yapı yer almaktadır. Train verisinde target etiketi yer alırken test verisinde yer almamaktadır.

Ana başvuru tablosundaki bureau ve bureau_balance tabloları başvuranın diğer finansal kuruluşlardaki kredi geçmişini ve aylık düzeydeki durum bilgisini içermektedir. Previous_application tablosu başvuranın daha önce yaptığı başvuruları temsil etmektedir. POS_CASH_balance ve credit_card_balance tabloları başvuranın önceki nakit kredi ürünleri ve kredi kartı bakiyelerinin aylık değişikliğini göstermektedir. Installments_payments tablosu önceki kredilerdeki ödeme performansını ve kaçırılan ödemeleri göstermektedir. Tüm veri dosyaları ve veri değişkenleri hakkında açıklamalar Çizelge 1’de listelenmiştir.

Çizelge 1. Veri değişkenleri

Adı	Türü	Amacı
SK_ID_CURR	Tamsayı	Başvuru anahtarı
TARGET	Tamsayı	Temerrüt hedefi

Adı	Türü	Amacı
CODE_GENDER	Kategorik	Başvuru demografik girdisi
FLAG_OWN_CAR	Kategorik	Varlık göstergesi
FLAG_OWN_REALTY	Kategorik	Varlık göstergesi
DAYS_BIRTH	Sayısal	Yaş bilgisi
DAYS_EMPLOYED	Sayısal	İstihdam süresi bilgisi
AMT_INCOME_TOTAL	Sayısal	Toplam gelir
AMT_CREDIT	Sayısal	Talep edilen kredi tutarı
AMT_ANNUITY	Sayısal	Taksit/annüite tutarı
CNT_FAM_MEMBERS	Sayısal	Hane büyüklüğü
SK_ID_BUREAU	Tamsayı	Bureau–balance anahtarı
DAYS_CREDIT	Sayısal	Büro kredi zaman bilgisi
DAYS_CREDIT_ENDDATE	Sayısal	Büro kredi bitiş zaman bilgisi
DAYS_CREDIT_UPDATE	Sayısal	Büro kayıt güncelleme bilgisi
CREDIT_DAY_OVERDUE	Sayısal	Büro gecikme gün bilgisi
AMT_CREDIT_MAX_OVERDUE	Sayısal	Büro max gecikme tutarı
AMT_CREDIT_SUM	Sayısal	Büro kredi toplam tutarı
AMT_CREDIT_SUM_DEBT	Sayısal	Büro borç tutarı
AMT_CREDIT_SUM_OVERDUE	Sayısal	Büro gecikme tutarı
AMT_CREDIT_SUM_LIMIT	Sayısal	Büro limit tutarı
CNT_CREDIT_PROLONG	Sayısal	Büro uzatma sayısı

Adı	Türü	Amacı
MONTHS_BALANCE	Sayısal	Zaman endeksi
SK_ID_PREV	Tamsayı	Geçmiş başvuru anahtarı
NAME_CONTRACT_STATUS	Kategorik	Sözleşme durumu
AMT_APPLICATION	Sayısal	Geçmiş başvuruda talep tutarı
AMT_CREDIT (prev)	Sayısal	Geçmiş başvuruda kredi tutarı
AMT_DOWN_PAYMENT	Sayısal	Peşinat
AMT_GOODS_PRICE	Sayısal	Mal/hizmet fiyatı
HOUR_APPR_PROCESS_START	Sayısal	Başvuru saat bilgisi
RATE_DOWN_PAYMENT	Sayısal	Peşinat oranı
DAYS_DECISION	Sayısal	Karar zamanı
CNT_PAYMENT	Sayısal	Taksit sayısı
CNT_INSTALLMENT	Sayısal	POS taksit sayısı
CNT_INSTALLMENT_FUTURE	Sayısal	POS kalan taksit
SK_DPD	Sayısal	POS gecikme göstergesi
SK_DPD_DEF	Sayısal	POS temerrüt gecikme göstergesi
NUM_INSTALLMENT_VERSION	Sayısal	Ödeme planı versiyonu
DAYS_INSTALLMENT	Sayısal	Vade günü
DAYS_ENTRY_PAYMENT	Sayısal	Ödeme günü
AMT_INSTALLMENT	Sayısal	Beklenen ödeme

Adı	Türü	Amacı
AMT_PAYMENT	Sayısal	Gerçekleşen ödeme
CREDIT_CARD_BALANCE	Sayısal	Kart davranış sinyalleri

3.2.VERİ ÖN İŞLEME VE ÖZELLİK MÜHENDİSLİĞİ

Bu aşamada amaç çok tablolü yapının tek başvuru şeklinde bir toplu matris haline getirilmesi ve modelin öğrenebileceği sayısal bir yapı kurulmasıdır. Bu amaçla application_train ve application_test birleştirilmiştir. Eğitim ve test tarafında aynı kategorik uzayın oluşması ve one hot kodlamanın bu aşamalar arasında farklı kolonlar üretmesi önlenmiştir. Ana başvuru tablosundaki değerlerin ölçek etkisini azaltmak ve ödeme gücüyle borç yükü arasındaki ilişkiyi yakalamak için oransal değişkenler üretilmiştir. Yardımcı veriler farklı kayıt sayılarına sahip oldukları için başvuran kimliği üzerinden özet istatistikler üretilmiştir. Ayrıca talep edilen kredi tutarının kullandırma tutarına oranı Denklem (1) ile hesaplanmıştır.

$$ACp = \frac{AAP}{ACP}$$

(1)

Planlanan taksit ile gerçekleşen ödeme arasındaki farkı yansıtmak için Denklem (2)'teki değişkenler üretilmiştir.

$$PP = \frac{AP}{AIst}, PDif = AIst - AP$$

(2)

Modellemeye geçmeden önce LightGBM yalnız sayısal değer kabul ettiği için tüm kolonlar sayısal tipe dönüştürülmüştür. Dönüştürülemeyen değerler NaN olarak bırakılmıştır. Hatalı tip dönüşümlerinden kaynaklı kırılmalar önlenmiştir. Tutarlı bir özellik uzayında eğitim tahmin girdisi üretmiştir.

3.3.MODELLEME VE DOĞRULAMA

Çalışmada tanımladığımız ikili sınıflandırma probleminin modellenmesi için LightGBM kullanılmıştır. Boosting sürecinde öğrenme oranı düşük tutulmuş ve daha kararlı bir yapı kurulmuştur. Maksimum ağaç sayısı 10000 olarak belirlenmiştir. Bölünmelerin sadece anlamlı kazançlarda uygulanması için min split kazanımı 0.0222415 olarak belirlenmiştir. Yaprak yapısında aşırı bölünmeyi önlemek amacıyla min child ağırlığı 39.3259775 olarak belirlenmiştir. Modelin genellenebilirliğine güvenilirlik sağlamak ve tek bir train test ayırımına bağlı kalmamak için K Fold yöntemi kullanılmıştır. Veri 10 katmana ayrılmış ve her iterasyonda 9 katman eğitim 1 katman test için kullanılmıştır. Bu sayede örneklem içerisinde dengeli ve genellenebilir eğitim ve test süreci sağlanmıştır. Doğrulama için AUC değeri hesaplanmıştır ve 200 iterasyon boyunca iyileşme görülmediğinde eğitim sonlanmıştır. En iyi iterasyonlar ayrıca raporlanmıştır. Olasılık tahmini için en iyi iterasyonun değeri alınmıştır. Doğrulama analizlerinin yapısı için genel bir sonuç elde etmek amacıyla tüm foldlar üzerinden (OOF) değerleri hesaplanmıştır.

3.4.PERFORMANS ÖLÇÜMÜ VE KALİTE KONTROLLERİ

Performans ölçümü KS, Kalibrasyon eğrisi ve Brier değeri, PSI analizi kullanılarak yapılmıştır. OOF yaklaşımı bu analizlerin hepsinde uygulanmıştır. KS analizi için TPR ve FPR değerlerinin hesaplanması ve farklarının alınması Denklem (3) kullanılarak yapılmıştır.

$$TPR(k) = \frac{\sum_{i=1}^k \mathbb{1}(y_i = 1)}{\sum_{i=1}^N \mathbb{1}(y_i = 1)}, FPR(k) = \frac{\sum_{i=1}^k \mathbb{1}(y_i = 0)}{\sum_{i=1}^N \mathbb{1}(y_i = 0)}, KS = \max_k | TPR(k) - FPR(k) |$$

(3)

Olasılık tahminlerinin kalibrasyon değerlendirmesi Brier skoru yöntemiyle Denklem (4) kullanılarak hesaplanmıştır.

$$Brier = \frac{1}{N} \sum_{i=1}^N (p_i - y_i)^2$$

(4)

Test verisinde etiket bulunmadığı için dağılım kayması ve skor stabilitesini incelemek üzere PSI analizi yapılmıştır. Referans olarak OOF skor dağılımı karşılaştırma olarak test skor dağılımı kullanılmıştır. Çalışmada bu analiz Denklem (5) kullanılarak yapılmıştır.

$$PSI = \sum_{b=1}^B (q_b - p_b) \ln \left(\frac{q_b}{p_b} \right)$$

(5)

3.5.KARAR EŞİĞİ OPTİMİZASYONU VE POLİTİKA ANALİZİ

Skor tahminlemesinden karar katmanına geçişte maliyet temelli bir eşikleme yöntemi kullanılmıştır. Bu yöntemde FP değeri kayıp maliyetiyle FN değeri fırsat maliyetiyle çarpılmış ve bunların toplamından oluşan tahsis süreci için minimum maliyet Denklem (6) kullanılarak hesaplanmıştır. ($c_{FN}=20$, $c_{FP}=1$).

$$C(t) = c_{FP} \cdot FP(t) + c_{FN} \cdot FN(t), t^* = \arg \min_{t \in [0,1]} C(t)$$

(6)

Belirlenen eşik üzerinden confusion matrisi hazırlanmıştır. Bu sayede eşik seçiminin ve maliyet temelli karar yapısının etkisi görünür kılınmıştır. Başvurular Denklem (7)'de verilen karar kuralına uygun olarak sınıflara atanmıştır.

$$Reject(t) = \mathbb{1}(p \geq t), Accept(t) = \mathbb{1}(p < t)$$

(7)

Eşikleme tek başına global sonuç üretebilmiştir. Modelin karar kuralının farklı ekonomik gruplarda nasıl etki ürettiğinin ayrıca izlenmesi gerekmektedir. Bu amaçla başvuru sahibinin ekonomik konumunu temsil etmesi kişi başı gelir seviyesi Denklem (8) kullanılarak hesaplanmış ve veri seti üç ekonomik sınıfa ayrılmıştır. Her grup için reddetme oranı ve beklenen hata türleri karşılaştırılmıştır.

$$INCOME_PER_PERSON = \frac{AMT_INCOME_TOTAL}{CNT_FAM_MEMBERS}$$

(8)

Başvuru sahiplerinin sınıflara ayrılması kullanılan kişi başı gelir seviyesinin örneklemin medyan değerine göre Denklem (9)(10)(11) üzerinden yapılmıştır.

$$LOW: INCOME_PER_PERSON < 0.60 \times Median(INCOME_PER_PERSON)$$

(9)


$$MID: 0.60 \times Median \leq INCOME_PER_PERSON \leq 2.00 \times Median$$

(10)


$$HIGH: INCOME_PER_PERSON > 2.00 \times Median.$$

(11)

Şekil 1. Test örnekleminde kişi başı gelir dağılımı



Şekil 2. Train ve Test kişi başı gelir yoğunluk histogramı



Kişi başı gelir seviyesi için hem eğitim setinde hem de eğitim test birleşiminde sağa çarpık bir yapı sergilemektedir. Ayrıca örneklem boyunca uç değerlerin varlığı sınıf ayrımı için medyan yaklaşımını en güvenilir yöntem olarak göstermiştir.

Gruplar arası karşılaştırma için üretilen reddetme oranı Denklem 12 kullanılarak üretilmiştir. Bu metrik aynı karar eşiği uygulandığında hangi grubun daha yüksek oranda reddedildiğini göstermiştir.

$$Reject_Rate = P(\widehat{PD} \geq cutoff).$$

(12)

Test veri setinde gerçek *TARGET* etiketleri bulunmadığı için hata türleri PD skorları üzerinden beklenen değer olarak Denklem (13)(14) kullanılarak hesaplanmıştır.

$$E[(1 - \widehat{PD}) \cdot I(\widehat{PD} \geq cutoff)]$$

(13)

$$E[\widehat{PD} \cdot I(\widehat{PD} < cutoff)]$$

(14)

Gruplar arası olası politika farklılıklarının yalnızca gelir seviyesinden kaynaklanan doğrudan bir etki mi yoksa gelirle ilişkili fakat karar mekanizmasını daha doğrudan tetikleyen bir başka değişken üzerinden mi ortaya çıktığının araştırılması gerekmektedir. Bu amaçla literatürde yer alan talep edilen kredi tutarı üzerinden etki ettiği iddiası hipotez olarak ele alınmış ve bahsedilen değişkenlere kontrollü değişikliklerin yapıldığı senaryolar üretilmiştir [4,5,35-39].

Böylece aynı başvuru için talep edilen kredinin değişmesinin modelin ürettiği risk skorlarını ve buna bağlı politika çıktılarını nasıl etkilediği grup bazında gözlemlenebilmiştir. Senaryo kurgusu iki yönlü değişiklikten oluşturulmuştur. Kredi tutarının azaltıldığı down senaryosu (-%20) ve kredi tutarının artırıldığı up senaryosu (+%20) hazırlanmıştır. Seçilen $\pm\%20$ bandı talep edilen kredi tutarı için operasyonel olarak anlamlı fakat aşırı gitmeyecek şekilde seçilmiştir. Veri setindeki diğer değişkenler sabit tutulmuş ve (down, normal, up) senaryoları için yeniden tahminleme önceden eğitilmiş olan aynı model kullanılarak yapılmıştır. Her senaryo için tüm gruplara yönelik reddedilme oranı ve hata oranları yeniden hesaplanmış ve karşılaştırılmıştır.

3.6. MODEL YAPI ANALİZİ


Modelin açıklanabilirliğini arttırmak, karar mantığını desteklemek amacıyla yapı analiz ve değişken önem analizleri uygulanmıştır. Bu analiz için Shap analizi yöntemlerinden LightGBM için uygun olan TreeShap yöntemi kullanılmıştır. Model K Fold yöntemiyle eğitildiği için Shap değerlerinin hesaplanmasında OOF yöntemi kullanılmıştır. Beeswarm grafiği ile her özelliğin SHAP dağılımı görselleştirilmiştir. Bar grafiği ile değişkenlerin önem sıralaması üretilmiştir. Ayrıca modelin en etkili gördüğü ilk 3 değişken için bağımlılık grafikleri üretilmiştir.

SHAP analizinin temel nedeni modelin hangi sinyallere dayanarak skor ürettiğini göstermektir. Gelirle ilişkili oran değişkenlerinin veya kredi tutarıyla bağlantılı değişkenlerin modelde ne kadar yüksek katkı ürettiğinin analiz edilmesidir. Bu analiz grup farkları ve senaryo farklarını tartışmak için dayanak sağlamıştır.

4. BULGULAR


4.1.MODEL AYRIŞTIRMA BAŞARIMI

Şekil 3. ROC analizi (OOF skorları)



ROC eğrisi farklı karar eşiklerinde gerçek pozitif oranı ile yanlış pozitif oranı arasındaki değişimi göstermiştir. AUC değeri 0.7916 olarak hesaplanmıştır. Veri kümesinin alındığı yarışmada birinci olan Home Aloan takım bu değeri 0.8057olarak hesaplamıştır. Bu değer modelin temerrüt riskini sınıflandırma konusunda başarılı bir sonuç ürettiğini göstermiştir. Ayrıca modelin temerrüde düşen bir gözlemi temerrüde düşmeyen bir gözlemden daha yüksek risk skoru ile sıralama olasılığının yaklaşık %79 düzeyinde olduğunu göstermiştir.

Şekil 4. KS analizi (OOF skorları)



KS istatistiğinde skorlar sıralandığında toplam gerçek pozitif oranı ile toplam yanlış pozitif oranı arasındaki en büyük farkı temsil etmiştir. Bu farkın maksimum olduğu nokta modelin en belirgin biçimde ayırdığı bölgeyi göstermiştir (Şekil 4). KS=0.4410 değeri temerrüt ve temerrütsüz gözlemlerin anlamlı ölçüde ayrıştığını göstermiştir.

Maksimum ayrışmanın gerçekleştiği thr=0.0752 noktasında TPR-FPR farkının en yüksek seviyeye ulaştığını göstermiştir.


Çizelge 2. Fold sonuçları

fold	auc	best_iteration	n_train	n_valid
1	0.793993	1514	276756	30751
2	0.791002	1234	276756	30751
3	0.784845	1244	276756	30751
4	0.793841	1510	276756	30751
5	0.794701	1242	276756	30751
6	0.792861	1156	276756	30751
7	0.791143	1417	276756	30751
8	0.784279	1258	276756	30751
9	0.790436	1094	276756	30751
10	0.793200	1333	276757	30750

K Fold yapısında her fold için AUC, en iyi iterasyon değeri ve eğitim doğrulama örnek sayısı Çizelge 2’de verilmiştir.

4.2.OLASILIK KALİTESİ ANALİZİ

Şekil 5. Kalibrasyon eğrisi ve Brier skoru (OOF)




OOF olasılık çıktılarının kalibrasyonu PD tahminlerinin pozitif oranlarla uymunu değerlendiren kalibrasyon eğrisiyle incelenmiştir. Bu grafikte her bir nokta benzer PD değerine sahip gözlemlerin bir araya getirildiği bir grubu göstermektedir.

İdeal durumda noktaları 45° referans doğrusu üzerinde olmalıdır. Elde edilen kalibrasyon eğrisinde modelin referans doğrusuna yakın bir seyir izlediği görülmüştür. PD skorlarının gözlenen temerrütle tutarlı olduğunu göstermiştir (Şekil 5). Kalibrasyon performansı Brier skoruyla özetlenmiştir. Hesaplanan Brier=0.0656 değeri modelin olasılık çıktılarındaki hatasının sınırlı düzeyde olduğunu genellikle doğru sonuç ürettiğini göstermiştir (Şekil 5).

4.3. DAĞILIM VE STABİLİTE ANALİZİ


Şekil 6. PSI analizi (OOF vs Test skor dağılımı)



Model performansının genellenebilirliğini analiz etmek için PSI analizi yapılmıştır. PSI değeri 0.0088 olarak hesaplanmıştır (Şekil 6). Düşük PSI değerleri skor dağılımının örneklemeler arasında yüksek oranda stabil olduğunu göstermiştir. Şekil 6'daki çubuklar beklenen ve gerçekleşen oranların yakın seyrettiğini sapmaların ise sınırlı düzeyde kaldığını göstermiştir. Bu sonuç modelin eğitimde öğrendiği risk yapısını teste aktarırken belirgin bir bozulma yaşanmadığını ve skorların kararlılığının korunduğunu göstermiştir.


4.4. MALİYET TEMELLİ OPTİMUM EŞİK VE HATA MATRİSİ

Şekil 7. Maliyet-eşik (cost curve) analizi



Eşik 0 ile 1 arasında taranarak elde edilen maliyet eğrisi eşik değeri azaldıkça daha fazla gözlemin riskli sınıfa geçtiğini ve fırsat maliyetinin yükseldiğini göstermiştir. Eşik arttıkça ise daha fazla temerrütün risksiz sınıfta kaldığı ve kayıp maliyetinin arttığını göstermiştir. Bu iki etkinin bileşkesi olarak eğrinin maliyeti minimize eden optimum eşik değeri 0.085 olarak belirlenmiştir (Şekil7).


Şekil 8. Confusion matrisi (maliyet-optimal eşik)



Belirlenen eşikçe göre üretilen confusion matrisi modelin hata türlerini ne oranda ürettiğini göstermiştir (Şekil 8). Bu eşik değerinde temerrütsüz 211916 gözlem doğru biçimde 0 olarak sınıflanırken 70766 gözlem yanlış biçimde 1 olarak sınıflanmıştır. Temerrütlü 17092 gözlem doğru biçimde 1 ve 7733 gözlem yanlış biçimde 0 olarak sınıflanmıştır.

4.5. DEĞİŞKEN ÖNEM VE MODEL ANALİZİ

Şekil 9. SHAP özet görselleştirmeleri (beeswarm + ortalama önem sıralaması)




Global önem sıralaması model sonuçlarında varyasyonun en büyük bölümünün dış kaynakla etkilendiğini göstermiştir. EXT_SOURCE_1 en belirleyici değişken olmuştur. Onu

EXT_SOURCE_3 ve EXT_SOURCE_2 izlemiştir. (Şekil 9). Dış kaynak değişkenlerinden sonra ACTIVE_DAYS_CREDIT_MAX ve PAYMENT_RATE değişkenlerinin önemli katkısının olduğu görülmüştür (Şekil 9).

SHAP özet grafiği bu değişkenlerdeki yüksek veya düşük değerlerin model sonucunu hangi yönde etkilediğini göstermiştir (Şekil 9). EXT_SOURCE değişkenlerinde düşük değerler pozitif SHAP katkıları sağlarken yüksek değerler negatif SHAP katkıları sağlamıştır (Şekil 9). Bu durum dış kaynak skorlarının risk azaltıcı yönde genel etki sergilediğini ve modelin bu sinyali güçlü biçimde kullandığını göstermiştir.


Şekil 10. Bağımlılık grafikleri (EXT_SOURCE_1 / EXT_SOURCE_2 / EXT_SOURCE3)



Dış kaynak değişkenlerinin etkisi bağımlılık grafikleri üzerinden daha ayrıntılı biçimde değerlendirildiğinde güçlü ve belirgin bir azalan ilişki görülmüştür. EXT_SOURCE_1 arttıkça SHAP katkısının düştüğü ve yüksek değerlerde katkının negatif olduğu görülmüştür (Şekil 10). EXT_SOURCE_2 ve EXT_SOURCE_3 artışlarının temerrüt yönündeki katkıyı azalttığı ve özellikle orta yüksek değer aralıklarında risk azaltıcı etkinin arttığı görülmüştür (Şekil 10). Bu üç grafiğin değerlendirilmesi modelin en yüksek ayrıştırma gücünü dış kaynak skorları tarafından sağlandığını ve model içinde tutarlı şekilde işlendiğini göstermiştir.


4.6.EKONOMİK SEGMENTLER ARASI KARŞILAŞTIRMA

Şekil 11. Sosyoekonomik segmentlere göre PD skor dağılımları




PD skorlarının grup dağılımında üç grubun tamamında skorların düşük değerlerde toplandığı ve sağ kuyruklu bir yapısının olduğu görülmüştür. Ayrıca gruplar arasında dağılımın yapısı aynı değildir. Düşük gelir grubunda dağılımın daha yüksek PD bölgesinde daha fazla toplandığı ayrıca cut-off'un sağında kalan bölümün daha fazla olduğu görülmüştür. Yüksek gelir grubu daha düşük PD bölgesinde daha çok toplanmıştır. Cut-off'un sağında kalan bölümün daha az olduğu gözlenmiştir (Şekil 11).

Şekil 12. Sosyoekonomik segmentlere göre reddetme oranı karşılaştırması



Bu ayrışmanın karar sonucuna nasıl etki ettiği ret oranı grafiğiyle değerlendirilmiştir. Ret oranları ekonomik düzey azaldıkça artan bir trend yapısı göstermiştir. Gelir seviyesi düştükçe tek eşikli politikanın daha çok ret ürettiği gözlenmiştir. Sonuç olarak gruplar arası farkın tesadüfen değil ekonomik gruplar arasında bir trend yapısı gösterdiği iddiası güçlenmiştir.

Şekil 13. Sosyoekonomik segmentlere göre beklenen hata tipi oranları karşılaştırması



Beklenen hata oranları gruplar arasında karşılaştırılmıştır. Burada yine ekonomik gruplar arasındaki farkların trend yapısı oluşturduğu görülmüştür. Beklenen iyi reddi oranı HIGH'tan LOW'a gidildikçe artmıştır. Beklenen kötü kabul oranı HIGH'tan LOW'a gidildikçe azalmıştır. Düşük gelir grubunda politika daha sıkı çalışmış, riskli kabul azalmış ve iynin reddedilmesi oranı artmıştır. Yüksek gelir grubunda politika daha gevşek çalışmış, riskli kabul olasılığı yükselmiş, iynin reddi oranları düşmüştür. Bu yapı tek eşikli politikanın gruplar arasında eşit bir hata sonucu üretmediğini göstermiştir. (Şekil 13)

Çizelge 3. Sosyoekonomik segmentlere göre politika çıktıları özet metrikleri

Group	n	Reject_rate	Exp_GoodRej_rate	Exp_BadAcc_rate
HIGH	6199	0.243426	0.214280	0.360996
MID	32480	0.258805	0.228863	0.353633
LOW	10065	0.281669	0.250522	0.336093
LOW-HIGH gap		0.038243	0.036242	-0.024902

Ekonomik sınıflar arasındaki etki için yapılan bu analizlerin sayısal sonuçları Çizelge 3’te raporlanmıştır. Ekonomik sınıflar arasında yapılan bu analizlerin sonucu olarak tek eşikli karar kuralının tüm kalemlerde düşük ekonomik grubun aleyhine olacak şekilde yanlı bir sonuç ürettiği görülmüştür. Gelir seviyesi arttıkça kötü kabulün artmasına rağmen tahsis oranları da artmış iynin reddedilmesi düşmüştür. Gelir seviyesi azaldıkça iynin reddedilmesinin artmasına rağmen tahsis oranı azalmakta ve kötü kabul oranı azalmaktadır.

4.7. SENARYO ANALİZİ

Çizelge 4. HIGH segmenti için kredi tutarı senaryo analizi çıktıları

Scenario	Multiple	n	Reject_rate	GoodRejection_rate	BadAcceptance_rate	GoodReject_count	BadAccept_count
down	-20%	6199	0.198580	0.176461	0.446213	1029.76	162.15
normal	1	6199	0.243426	0.214280	0.360996	1237.16	153.57
up	20%	6199	0.233586	0.206722	0.394396	1195.17	164.66

HIGH grupta down senaryosu ret oranını 0.243’ten 0.199’a düşürerek politika gevşemesi üretmiştir. İyi reddi oranı da 0.214’ten 0.176’ya düşmüş ve kötü kabul oranının 0.361’den 0.446’ya yükselmesi tahsis oranının artmasıyla riskli kabulün de arttığını göstermiştir. Up senaryosunda değişimler daha sınırlı olmuştur. Ret oranı ve iyi reddi azalmıştır. Kötü kabul artmıştır (Çizelge 4).

Çizelge 5. MID segmenti için kredi tutarı senaryo analizi çıktıları

Scenario	Multiple	n	Reject_rate	GoodRejection_rate	BadAcceptance_rate	GoodReject_count	BadAccept_count
down	-20%	32480	0.214009	0.191106	0.436001	5825.89	869.77
normal	1	32480	0.258805	0.228863	0.353633	6900.36	823.75
up	20%	32480	0.254341	0.226558	0.380430	6838.43	873.49

MID grupta down senaryosu ret oranını ve iyi reddini azaltmış, kötü kabul oranını yükseltmiştir. Up senaryosunda ise ret oranı ve iyi reddindeki azalma sınırlı kalmış, kötü kabul oranı artmıştır.

Çizelge 6. LOW segmenti için kredi tutarı senaryo analizi çıktıları

Scenario	Multiple	n	Reject_rate	GoodRejection_rate	BadAcceptance_rate	GoodReject_count	BadAccept_count
down	-20%	10065	0.230005	0.206480	0.424932	1945.58	272.97
normal	1	10065	0.281669	0.250522	0.336093	2331.51	254.88
up	20%	10065	0.275807	0.247196	0.366135	2303.92	272.68

LOW grupta down senaryosu ret oranını daha da güçlü düşürmüş, iyi reddi de anlamlı biçimde azalmıştır. Kötü kabul oranı 0.336'dan 0.425'e yükselmiştir. Up senaryosu daha az ret azalması üretmiş, iyi reddini az da olsa düşürmüş ve kötü kabul oranını artırmıştır (Çizelge 6).

5. TARTIŞMA

Modelin ayırıştırma başarımı için hesaplanan $AUC = 0.7916$ ve $KS=0.4410$ değerleri model performansının güvenilir ve kullanılabilir olduğunu göstermiştir. Kalibrasyon analiziyle olasılık kalitesinin analiz edilmesi için hesaplanan Brier = 0.0656 değeri modelin olasılık sonucu üretme konusunda güvenilir ve sınırlı hata üreten bir yapıda olduğunu göstermiştir. Elde edilen bu model başarısının genellenebilirliğini göstermek için hesaplanan $PSI = 0.0088$ değeri modelin sonuçlarının stabil olduğunu göstermiştir.

Bu başarıya sahip modelin maliyet temelli bir karar kuralına dönüştürülmesi için tanımlanan kayıp maliyeti = 20 ve fırsat maliyeti = 1 oranlarına göre cut off eşiği = 0.085 hesaplanmıştır. Bu eşiğe göre verilen karar kuralı sonucu modelin 211916 temerrütsüz sonucu başarılı şekilde iyi, 17092 temerrüd sonucunu başarılı şekilde kötü olarak sınıflandırdığı görülmüştür. Buna karşın 70766 temerrütsüz sonuç hatalı olarak kötü, 7733 temerrüt sonucu hatalı olarak iyi olarak sınıflandırılmıştır. Bu durum maliyet temelli karar kuralının politika sonuçlarını göstermiştir.

Ekonomik sınıflar arasında karar kuralının analiz edilmesi için yapılan analizlerden olasılık dağılımı analizinde düşük sınıftan yüksek sınıfa gittikçe gözlemlerin düşük risk sınıfında toplandığı ve eşiğin sağında daha az kaldığı görülmüştür. Bu yapı ekonomik gruplar arasındaki farkın düzenli bir değişimde olma ihtimalini düşündürmüştür. Bu yüzden reddedilme oranlarını karşılaştırılmış ve benzer bir yapı orada da gözlenmiştir. HIGH gruptan LOW gruba ilerledikçe reddedilme oranındaki değişimin düzenli bir trend yapısı oluşturduğu görülmüştür. Bu yapı ekonomik gruplar arasındaki bu değişimin HIGH grup lehinde bir yanlılık gösterme olasılığını düşündürmüştür. Bu amaçla yapılan hata tipi oranları karşılaştırılmasında bu düşüncüyü destekleyen sonuçlar gözlenmiştir. Kötü kabul oranları HIGH gruptan LOW gruba düzenli bir trend yapısı içinde azalmıştır. İyi reddi oranı ise HIGH gruptan LOW gruba düzenli bir şekilde artmıştır. Bu yapı tek eşikli karar kuralının gelir düzeyi azaldıkça daha sıkı çalıştığını ve tahsis oranını anlamlı ölçüde düşürdüğünü göstermiştir. Güler düzeyi arttıkça karar kuralı gevşemiş ve tahsis oranını arttırmıştır. Bu analizler tek eşikli karar kuralının tüm kalemlerde HIGH grup lehine bir yanlılık sergilediğini ve ekonomik gruplar arasındaki değişimin düzenli bir trend yapısı içerisinde olduğunu göstermiştir.

Ekonomik gruplar arasındaki bu yapının sebebinin araştırılması ve literatürdeki “Gelir seviyesi doğrudan değil talep edilen kredi tutarı ve bağlantılı veriler üzerinden etki etmektedir” hipotezinin test edilmesi için uygulanan senaryo analizinin sonuçlarında beklenenin aksine talep edilen kredi tutarı ve bağlantılı verilere uygulanan kontrollü değişikliklerin ekonomik sınıflar arasındaki trend yapısında anlamlı değişim üretemediği görülmüştür [4,5,35-39]. Down senaryosunda tüm gruplarda karar politikası gevşemiş reddedilme oranları düşmüştür. İyinin reddedilmesi oranları düşmüş ve kötü kabul oranları artmıştır. Up senaryosunda yine karar kuralı gevşemiş tüm gruplarda reddedilme oranları daha az olsada azalmıştır. İyi reddedilme oranı azalmış ve kötü kabul oranları artmıştır. Up senaryosunda sonuçların beklenen aksine down senaryosuyla aynı yönde olduğu görülmüştür. Bu analiz sonucunda Down senaryosu en çok LOW grubu değiştirmiş, Up senaryosu en çok HIGH grubu değiştirmiştir. Her iki senaryoda da en stabil kalan MID grup olmuştur.

Çizelge 7. Senaryo analizi özet değişimler

Segment	Senaryo	Ret Oranı (%)	İyi Reddi Oranı (%)	Kötü Kabul Oranı (%)	İyi Red Sayısı (%)	Kötü Kabul Sayısı (%)
HIGH	Down	-18.42	-18.55	+28.59	-16.76	+5.59
HIGH	Up	-4.04	-3.55	-1.86	-3.39	+7.22
MID	Down	-17.37	-16.41	+20.46	-10.37	+16.51
MID	Up	-1.80	-0.92	+11.42	-1.72	+6.04
LOW	Down	-18.34	-17.58	+26.43	-16.55	+7.06
LOW	Up	-2.08	-1.33	+8.94	-1.18	+6.94

Hipotezin test sonuçlarında senaryo analizinin ekonomik gruplar arasındaki yanlılık ve trend yapılarının bozulması veya anlamlı şekilde azalması beklenmiştir. Elde edilen sonuçlara göre senaryo analizi beklenen sonuçları üretememiş literatürdeki bu hipotezi destekleyememiş aksine anlamlı bir karşılığının olmadığını göstermiştir. Gelir seviyesi etkisinin talep edilen kredi tutarı ve bağlantılı değişkenler üzerinden değil doğrudan veya farklı bir yapı üzerinden etki ettiğini göstermiştir. Bu etkinin kaynağının ayrıca analiz edilmesi gerektiğini göstermiştir.

Değişken önem analizinde modelin çoğunlukla EXT_SOURCE_1, EXT_SOURCE_2 ve EXT_SOURCE_3 değişkenleri gibi dış değişkenlerden etkilendiğini göstermiştir. Ayrıca ACTIVE_DAYS_CREDIT_MAX ve PAYMENT_RATE gibi aktif kredi ve borç kapasitesini gösteren değişkenlerden etkilendiği gözlenmiştir. Shap özet grafiğinde EXT_SOURCE değişkenlerinin düşük değerlerinin pozitif yüksek değerlerinin ise negatif katkı ürettiği görülmüştür. Bağımlılık grafiklerinde EXT_SOURCE değişkenlerinin değeri arttıkça katkısının düştüğü yüksek değerlerde katkının negatif olduğu görülmüştür. Bu analizler modelin ayrıştırma gücünü belirleyen en güçlü etkinin dış kaynaklardan geldiğini ve bu yapının model içinde dengeli etki sağladığını göstermiştir.

Değişken önem analizi sonuçları senaryo analizi sonucu elde edilen sonucu desteklemiştir. Buna göre modelin karar kuralındaki değişiklikler dış faktörler, aktif kredi ve borçlanma yükü vb. değişkenlerden güçlü şekilde etkilenmiştir. Gelir seviyesi değiştikçe başvuru sahiplerinin dış faktör etkilerinin ve borçlanma yükünün anlamlı şekilde değişeceği ve gelir seviyesinden kaynaklanan ekonomik sınıflar arasındaki farkın yanlılık ve trend değişimlerinin de bu sebeple değişeceği görülmüştür.

6. SONUÇ

Bu çalışmada kredi tahsisinde temerrüt olasılığının tahmin edilmesi için makine öğrenmesi kullanılmıştır. Ayırıştırma başarımı, olasılık kalitesi ve stabilitesi yüksek bir model geliştirilmek, olasılık tahminleri maliyet oranları kullanılarak maliyet temelli karar eşiği kullanmak, tek eşikli karar kuralının ekonomik gruplar arasında nasıl etki gösterdiğini analiz etmek ve olası etkilerin kaynaklarını tespit etmek amaçlanmıştır.

Bu amaçla LightGBM modeli kurularak temerrüt olasılığı tahmin edilmiştir. Yanlış pozitif oranı ve yanlış negatif oranı üzerinden kayıp maliyeti ve fırsat maliyeti verileri kullanılarak tek eşikli bir maliyet eşiği belirlenmiştir. Belirlenen bu eşiğin karar kuralı olarak uygulanmasıyla olasılık tahminlerinin karar kuralı haline getirilmesi politikasının analiz edilmesi sağlanmıştır. Confusion matrisinde görülen değerler bu politikanın etkilerini göstermiştir (Şekil 8). Tek eşikli karar kuralının ekonomik sınıflar arasında nasıl bir etki ürettiğinin analiz edilmesi için test verisi 3 ekonomik gruba ayrılmıştır. Bu gruplar arasında yapılan analizler sonucunda tek eşikli karar kuralının HIGH ekonomik sınıfa yanlılık gösterdiği ve daha olumlu sonuçlar oluşturduğu görülmüştür. HIGH gruptan LOW gruba doğru düzenli bir trend yapısında reddedilme oranlarının arttığı, iyinin reddedilmesi oranının arttığı ve kötü kabul oranının düştüğü gözlenmiştir. Bu değişimin sebebinin analiz edilmesi için yapılan araştırmalarda literatürdeki “Gelir seviyesinin kredi tahsis kararına etkisi doğrudan değil talep edilen kredi tutarı ve onunla bağlantılı değişkenler üzerinden etki etmektedir” iddiası hipotez olarak ele alınmış ve test edilmiştir [4,5,35-39].

Bu test için bahsedilen değişkenlere kontrollü değişiklikler uygulanmıştır. Down senaryosunda karar politikası beklendiği gibi gevşemiş reddedilme oranları ve iyi reddi oranı azalmış, kötü kabul oranı artmıştır. Up senaryosunda beklenin aksine politika sıkılaşmamış gevşemiştir. Down senaryosuna göre daha az olsada reddedilme oranları ve iyi reddi oranı düşmüş, kötü kabul oranı artmıştır. Down senaryosu en çok LOW grupta değişim yapmıştır. Up senaryosu ise en çok HIGH grupta değişim yapmıştır. Bu analizin ana amacı olan gelir seviyesindeki trend yapısı açısından anlamlı bir değişiklik üretememiştir. Bu analize göre talep edilen kredi tutarı üzerindeki kontrollü değişiklikler gelir seviyesi etkileri üzerinde anlamlı bir etki üretememektedir. Test edilen hipotez doğrulanamamış ve kabul edilememiştir. Elde edilen

sonuç gelir seviyesinin talep edilen kredi tutarı üzerinden değil doğrudan veya farklı bir yapı üzerinden kredi tahsisine etki ettiğini göstermiştir.

Bu yapının daha detaylı analiz edilmesi gerektiği için eğitilen model için model yapı analizi uygulanmıştır. Bu analizin sonuçlarına göre model çoğunlukla dış faktörlerden etkilenmiş, ayrıca başvuru sahibinin aktif kredilerinin zaman boyutundan ve borçlanma kapasitesinden etkilendiği gözlenmiştir. Bu analizde özellikle dış kaynak değişkenlerindeki artışın katkısı negatif etkilediği gözlenmiştir. Bağımlılık grafiklerinde dış kaynak değişken değerlerindeki artışın temerrüt yönündeki katkısı azalttığı, özellikle yüksek değerlerde risk azaltıcı etkisinin kaybolduğu görülmüştür.

Bu sonuçlar gelir seviyesinin kredi tahsisine olan etkisinin dış kaynak değişkenleri, özellikle aktif kredi zaman değeri ve borçlanma kapasitesi değişkenleri üzerinden etki ettiğini göstermiştir.

Bu çalışma kredi tahsis literatürüne doğru ve adil karar kuralı seçmek konusunda ışık tutmuştur. Bu çalışma tek eşik yerine her ekonomik sınıf için bir eşik değeri belirlenmesinin ya da veriyle uyumlu birden fazla eşikli bir karar politikasının ekonomik sınıflar arasında daha adil bir uygulama olacağını göstermiştir. Bu çalışma bireysel krediler için karar mekanizmaları alanlarında uygundur ama işletme kredileri için uygun değildir. Ayrıca bu çalışma için kullanılan veri seti belirli bir ülkedeki kullanıcı davranışlarını göstermektedir. Kültürel ve ekonomik farklılıklar sebebiyle farklı ülkelerdeki kullanıcı davranışlarıyla örtüşmeyebilir. Gelecek çalışmalarda hem maliyet hem fairness açısından en dengeli karar kuralı yapısının ne olduğunun incelenmesi hedeflenmektedir.

KAYNAKLAR

- [1] Hand, D. J. and Henley, W. E. (1997). Statistical classification methods in consumer credit scoring: a review. *Journal of the Royal Statistical Society: Series A (Statistics in Society)*, 160(3), 523–541.
- [2] Thomas, L. C. (2000). A survey of credit and behavioural scoring: forecasting financial risk of lending to consumers. *International Journal of Forecasting*, 16(2), 149–172.
- [3] Crook, J. N., Edelman, D. B. and Thomas, L. C. (2007). Recent developments in consumer credit risk assessment. *European Journal of Operational Research*, 183(3), 1447–1465. doi: 10.1016/j.ejor.2006.09.100.
- [4] Anderson, R. (2007). *The Credit Scoring Toolkit: Theory and Practice for Retail Credit Risk Management and Decision Automation*. Oxford University Press.
- [5] Siddiqi, N. (2012). *Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring*. John Wiley & Sons.
- [6] Baesens, B., Van Gestel, T., Viaene, S., Stepanova, M., Suykens, J. and Vanthienen, J. (2003). Benchmarking state-of-the-art classification algorithms for credit scoring. *Journal of the Operational Research Society*, 54(6), 627–635. doi: 10.1057/palgrave.jors.2601545.
- [7] Lessmann, S., Baesens, B., Seow, H.-V. and Thomas, L. C. (2015). Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research. *European Journal of Operational Research*, 247(1), 124–136. doi: 10.1016/j.ejor.2015.05.030.
- [8] Khandani, A. E., Kim, A. J. and Lo, A. W. (2010). Consumer credit-risk models via machine-learning algorithms. *Journal of Banking & Finance*, 34(11), 2767–2787.
- [9] Brown, I. and Mues, C. (2012). An experimental comparison of classification algorithms for imbalanced credit scoring data sets. *Expert Systems with Applications*, 39(3), 3446–3453.
- [10] Bellotti, T. and Crook, J. (2009). Support vector machines for credit scoring and discovery of significant features. *Expert Systems with Applications*, 36(2), 3302–3308.
- [11] Malekipirbazari, M. and Aksakalli, V. (2015). Risk assessment in social lending via random forests. *Expert Systems with Applications*, 42(10), 4621–4631. doi: 10.1016/j.eswa.2015.02.001.

- [12] Serrano-Cinca, C., Gutiérrez-Nieto, B. and López-Palacios, L. (2015). Determinants of default in P2P lending. PLoS ONE, 10(10), e0139427. doi: 10.1371/journal.pone.0139427.
- [13] Breiman, L., Friedman, J. H., Olshen, R. A. and Stone, C. J. (1984). Classification and Regression Trees. Wadsworth.
- [14] Breiman, L. (2001). Random forests. Machine Learning, 45, 5–32. doi: 10.1023/A:1010933404324.
- [15] Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. The Annals of Statistics, 29(5), 1189–1232.
- [16] Friedman, J. H. (2002). Stochastic gradient boosting. Computational Statistics & Data Analysis, 38(4), 367–378.
- [17] Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16), 785–794. doi: 10.1145/2939672.2939785.
- [18] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q. and Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. Advances in Neural Information Processing Systems (NeurIPS), 3146–3154.
- [19] Chawla, N. V., Bowyer, K. W., Hall, L. O. and Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. Journal of Artificial Intelligence Research, 16, 321–357. doi: 10.1613/jair.953.
- [20] He, H. and Garcia, E. A. (2009). Learning from imbalanced data. IEEE Transactions on Knowledge and Data Engineering, 21(9), 1263–1284. doi: 10.1109/TKDE.2008.239.
- [21] Bradley, A. P. (1997). The use of the area under the ROC curve in the evaluation of machine learning algorithms. Pattern Recognition, 30(7), 1145–1159.
- [22] Fawcett, T. (2006). An introduction to ROC analysis. Pattern Recognition Letters, 27(8), 861–874. doi: 10.1016/j.patrec.2005.10.010.
- [23] Davis, J. and Goadrich, M. (2006). The relationship between Precision-Recall and ROC curves. Proceedings of the 23rd International Conference on Machine Learning (ICML), 233–240. doi: 10.1145/1143844.1143874.

- [24] Saito, T. and Rehmsmeier, M. (2015). The Precision-Recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS ONE*, 10(3), e0118432. doi: 10.1371/journal.pone.0118432.
- [25] DeLong, E. R., DeLong, D. M. and Clarke-Pearson, D. L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: A nonparametric approach. *Biometrics*, 44(3), 837–845. doi: 10.2307/2531595.
- [26] Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1), 1–3. doi: 10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2.
- [27] Platt, J. (1999). Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In: *Advances in Large Margin Classifiers*. MIT Press, 61–74.
- [28] Zadrozny, B. and Elkan, C. (2002). Transforming classifier scores into accurate multiclass probability estimates. *Proceedings of the 8th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '02)*, 694–699. doi: 10.1145/775047.775151.
- [29] Niculescu-Mizil, A. and Caruana, R. (2005). Predicting good probabilities with supervised learning. *Proceedings of the 22nd International Conference on Machine Learning (ICML)*, 625–632.
- [30] Guo, C., Pleiss, G., Sun, Y. and Weinberger, K. Q. (2017). On calibration of modern neural networks. *Proceedings of the 34th International Conference on Machine Learning (ICML)*, 1321–1330.
- [31] Ribeiro, M. T., Singh, S. and Guestrin, C. (2016). “Why should I trust you?” Explaining the predictions of any classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16)*, 1135–1144. doi: 10.1145/2939672.2939778.
- [32] Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems (NeurIPS)*, 4765–4774.
- [33] Bergstra, J. and Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13, 281–305.

- [34] Yurdakul, B. and Naranjo, J. (2020). Statistical properties of the population stability index. *Journal of Risk Model Validation*, 14(4), 89–100. doi: 10.21314/JRMV.2020.227.
- [35] Engelmann, B. and Rauhmeier, R. (Eds.). (2006). *The Basel II Risk Parameters: Estimation, Validation, and Stress Testing*. Springer.
- [36] Board of Governors of the Federal Reserve System (2011). SR 11-7: Guidance on Model Risk Management (and attachment: Supervisory Guidance on Model Risk Management).
- [37] Office of the Comptroller of the Currency (OCC) (2011). OCC Bulletin 2011-12: Sound Practices for Model Risk Management.
- [38] European Banking Authority (EBA) (2020). Guidelines on loan origination and monitoring. EBA/GL/2020/06.
- [39] Basel Committee on Banking Supervision (BCBS) (2005). An explanatory note on the Basel II IRB risk weight functions.
- [40] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V. and others (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [41] McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference (SciPy)*, 56–61. doi: 10.25080/Majora-92bf1922-00a.
- [42] Harris, C. R., Millman, K. J., van der Walt, S. J. and others (2020). Array programming with NumPy. *Nature*, 585, 357–362. doi: 10.1038/s41586-020-2649-2.

TURNİTİN RAPORU



Sayfa 1 / 36 - Kapak Sayfası

Gönderi Kimliği trnold::1:3461019247

S K

Mustafa Çeşmeli

- Mustafa Çeşmeli
- BİTİRME ÖDEVLERİ
- Çukurova Üniversitesi

Belge Ayrıntıları

Gönderi Kimliği
trnold::1:3461019247

Gönderi Tarihi
20 Oca 2026 12:51 GMT+3

İndirme Tarihi
20 Oca 2026 12:55 GMT+3

Dosya Adı
Mustafa-Cesmeli-2022238019-Bitirme_Ödevi-Tez_-Kopya_-Kopya.docx

Dosya Boyutu
952.0 KB

33 Sayfa

5.305 Sözcük

38.771 Karakter



Sayfa 1 / 36 - Kapak Sayfası

Gönderi Kimliği trnold::1:3461019247

3% Genel Benzerlik

Her veri tabanı için çıkan kaynaklar da dâhil tüm eşleşmelerin kombine toplamı.

Ön Sıradaki Kaynaklar

- 2% İnternet kaynakları
- 1% Yayınlar
- 2% Gönderilen çalışmalar (Öğrenci Makaleleri)

Bütünlük Bayrakları

İnceleme için 0 Bütünlük Bayrağı

Herhangi bir şüpheli metin manipölasyonu belirlenmedi.

Sistemimizin algoritmaları bir belgede, onu normal bir gönderiden ayırmak için her türlü tutarsızlığı derinlemesine inceler. Tuhaf bir şey fark edersek incelemeniz için bayrak ekleriz.

Bir Bayrak mutlaka bir sorun olduğunu göstermez. Ancak daha fazla inceleme için dikkatinizi vermenizi öneririz.

Ön Sıradaki Kaynaklar

- 2%  İnternet kaynakları
- 1%  Yayınlar
- 2%  Gönderilen çalışmalar (Öğrenci Makaleleri)

Ön Sıradaki Kaynaklar

Gönderi içinde en yüksek eşleşme sayısına sahip kaynaklar. Çakışan kaynaklar görüntülenmeyecektir.

1	İnternet	harnalashok.github.io	<1%
2	İnternet	github.com	<1%
3	İnternet	hdl.handle.net	<1%
4	Öğrenci makaleleri	Harrisburg University of Science and Technology	<1%
5	Öğrenci makaleleri	The Scientific & Technological Research Council of Turkey (TUBITAK)	<1%
6	İnternet	acikbilim.yok.gov.tr	<1%
7	İnternet	emb.cu.edu.tr	<1%
8	Yayın	Samet Dinçer, Beste Üstübioğlu, Gül Tahaoğlu, Güzin Ulutaş. "Deep Fake Video D...	<1%

TEŞEKKÜR

Danışmanım Dr. Öğr. Üyesi Kübra ATEŞ'e, tez çalışmam boyunca sağladığı akademik yönlendirme, yapıcı geri bildirim ve destekleri için teşekkür ederim. Ayrıca eğitim hayatım ve bu çalışma sürecinde her aşamada yanımda olan aileme ve yakın çevreme, verdikleri moral ve motivasyon için teşekkürlerimi sunarım.

ÖZGEÇMİŞ

Mustafa Çeşmeli, 2002 yılında Erdemli’de doğmuştur. Ortaöğrenimini Erdemli Anadolu Lisesinde tamamlamıştır. Çukurova Üniversitesi Endüstri Mühendisliği lisans programında öğrenimini sürdürmekte olup mezuniyetinin 2027 yılında gerçekleşmesi öngörülmektedir. Akademik ve mesleki ilgi alanları analitik, proje yönetimi ve finans ekseninde şekillenmektedir. 2025 Nisan ayından itibaren uzaktan çalışma modeliyle Kodland’da ders eğitmeni olarak matematik, 2D animasyon, 3D modelleme, grafik tasarım ve temel bilgisayar okuryazarlığı alanlarında eğitimler yürütmekte; farklı kurslarda öğretim faaliyetlerine katkı sunmaktadır.